

Marco multiagente impulsado por LLM para el aprendizaje orientado a objetivos en un sistema de tutoría inteligente

Tianfu Wang HKUST (GZ) Guangzhou, China tianfuwang.cs@outlook.com	Yi Zhan Microsoft Inc. Suzhou, China zhan0119@outlook.com	Jianxun Lian Microsoft Research Asia Beijing, China jianxun.lian@outlook.com	Zhengyu Hu HKUST (GZ) Guangzhou, China zhu021@connect.hkust-gz.edu.cn
Nicholas Jing Yuan Microsoft Inc. Suzhou, China nicholas.yuan@microsoft.com	Qi Zhang Microsoft Inc. Suzhou, China zhang.qi@microsoft.com	Xing Xie Microsoft Research Asia Beijing, China xingx@microsoft.com	Hui Xiong HKUST (GZ) & HKUST Guangzhou, China xionghui@ust.hk

Resumen

Los sistemas de tutoría inteligente (ITS) han revolucionado la educación al ofrecer experiencias de aprendizaje personalizadas. Sin embargo, a medida que el aprendizaje orientado a objetivos, que enfatiza el logro eficiente de objetivos específicos, se vuelve cada vez más importante en los contextos profesionales, los ITS existentes a menudo tienen dificultades para ofrecer este tipo de experiencia de aprendizaje dirigido. En este trabajo, proponemos **GenMentor**, un marco de trabajo multiagente impulsado por LLM diseñado para ofrecer aprendizaje personalizado y orientado a objetivos dentro del ITS. GenMentor comienza por mapear con precisión los objetivos de los estudiantes a las habilidades requeridas utilizando un LLM afinado entrenado en un conjunto de datos personalizado de objetivo a habilidad. Después de identificar la brecha de habilidades, planifica un camino de aprendizaje eficiente utilizando un enfoque de optimización en evolución, impulsado por un perfil integral y dinámico del estado multifacético de los estudiantes. Además, GenMentor adapta el contenido de aprendizaje con un mecanismo de exploración-redacción-integración para alinearse con las necesidades individuales del alumno. Las extensas evaluaciones automatizadas y humanas demuestran la eficacia de GenMentor en la orientación del aprendizaje y la calidad del contenido. Además, lo hemos desplegado en la práctica y también lo hemos implementado como aplicación. El estudio humano práctico con estudiantes profesionales destaca aún más su efectividad en la alineación de objetivos y la focalización de recursos, lo que lleva a una mayor personalización. Recursos complementarios están disponibles en <https://github.com/GeminiLight/gen-mentor>.

Conceptos CCS

• **Sistemas de información** →

Minería web. Palabras clave

Sistema de tutoría inteligente, modelo de lenguaje grande, multiagente

Correspondiente autores.

Se concede permiso para hacer copias digitales o impresas de todo o parte de este trabajo para uso personal o en el aula sin costo, siempre que las copias no se hagan ni distribuyan con fines de lucro o ventaja comercial y que las copias lleven este aviso y la cita completa en la primera página. Se deben respetar los derechos de autor de los componentes de esta obra que sean propiedad de terceros distintos del autor o autores. Se permite la abstracción con crédito. Para copiar de otra manera, o volver a publicar, publicar en servidores o redistribuir a listas, se requiere permiso específico previo y/o una tarifa. Solicitar permisos a permissions@acm.org.

WWW Companion '25, Sydney, NSW, Australia

© 2025 Derechos de autor en manos del propietario/autor. Derechos de publicación otorgados a ACM. ACM ISBN 979-8-4007-1331-6/25/04 <https://doi.org/10.1145/3701716.3715244>

Formato de referencia ACM:

Tianfu Wang, Yi Zhan, Jianxun Lian, Zhengyu Hu, Nicholas Jing Yuan, Qi Zhang, Xing Xie y Hui Xiong. 2025. Marco multiagente impulsado por LLM: trabajo para el aprendizaje orientado a objetivos en un sistema de tutoría inteligente. Dentro *Actas de la Conferencia Web ACM 2025 (WWW Companion '25)*, del 28 de abril al 2 de mayo de 2025, Sydney, NSW, Australia. ACM, Nueva York, NY, USA, 10 páginas. <https://doi.org/10.1145/3701716.3715244>

1 Introducción

Los sistemas de tutoría inteligente (ITS) han hecho avances significativos en el apoyo a experiencias de aprendizaje personalizadas mediante el aprovechamiento de las tecnologías de aprendizaje automático (ML)[23]. Estos sistemas utilizan cada vez más información basada en datos sobre aspectos clave, como la gestión de los materiales de aprendizaje [19, 39], el perfilado del estado del alumno [10, 31] y la entrega de comentarios personalizados [13, 42]. Sin embargo, muchos ITS basados en ML sufren de fragmentación debido a inconsistencias técnicas entre los módulos. También exhiben una adaptabilidad limitada a temas emergentes, que a menudo requieren un readiestramiento extensivo para adaptarse a nuevos temas educativos. Recientemente, los grandes modelos de lenguaje (LLMs) han presentado nuevas oportunidades para mejorar el ITS al ofrecer retroalimentación interactiva a través de interfaces conversacionales [24]. Los estudios existentes sobre ITS basados en LLM [8, 20, 26] demuestran su facilitación en la generación de contenidos, respuesta a consultas y resolución de problemas. Sin embargo, si bien los LLMs sobresalen en la participación basada en el diálogo, a menudo siguen siendo reactivos, simplemente respondiendo a las preguntas de los alumnos sin guiarlos proactivamente hacia sus objetivos [21]. Esta reactividad también limita su capacidad para obtener una comprensión integral de los estudiantes, debilitando así la personalización [26].

A medida que las demandas educativas continúan diversificándose, especialmente dentro de los contextos de aprendizaje profesional y permanente, los estudiantes buscan cada vez más sistemas que apoyen objetivos personales o específicos de carrera [6]. Por ejemplo, un empleado asignado a una tarea o buscando nuevos empleos que involucren tecnología desconocida puede sentirse inseguro sobre dónde comenzar o qué habilidades específicas desarrollar. Sin una orientación clara, corren el riesgo de verse abrumados o perder tiempo con contenidos menos relevantes [1]. Estos estudiantes se beneficiarían de un sistema que colme esta brecha mediante la rápida identificación de sus deficiencias de conocimiento y la provisión de contenido dirigido para ayudarlos a adquirir las habilidades precisas necesarias para completar el objetivo de manera eficiente. Este enfoque personalizado, conocido como aprendizaje orientado a objetivos, va más allá de la mera entrega de información y se centra en guiar el logro de los objetivos [17]. Sin embargo, los ITS tradicionales a menudo se basan en planes de estudio estáticos, ofreciendo un contenido amplio




Figura 1: Comparación de tres tipos de paradigmas ITS.

que puede no abordar adecuadamente las necesidades únicas de los estudiantes individuales. Además, los ITS de diálogo basados en LLM tienden a ser reactivos en lugar de guiar activamente a los estudiantes para alcanzar sus metas. Como resultado, estos sistemas tienen dificultades para proporcionar una atención personalizada y orientada a objetivos, especialmente en contextos profesionales acelerados.

Para abordar estas brechas, proponemos un cambio de perspectiva hacia el aprendizaje orientado a objetivos para transformar los ITS. Como se ilustra en la figura 1, a diferencia de los ITS tradicionales que dependen principalmente de currículos estáticos o un compromiso reactivo, nuestro enfoque enfatiza de manera proactiva la capacidad de los estudiantes para alcanzar sus objetivos específicos. En los ITS orientados a objetivos, el proceso de aprendizaje está impulsado por los objetivos del alumno en lugar de un plan de estudios predefinido. Al identificar las brechas de habilidades y el estado del aprendiz que presenta, estos sistemas pueden ofrecer trayectorias más personalizadas y contenido adaptado, lo que permite a los estudiantes adquirir rápidamente las habilidades necesarias para alcanzar sus objetivos específicos. En particular, los LLMs tienen un potencial prometedor debido a su notable capacidad para entender intenciones complejas y generar contenido versátil [5, 7, 41], lo que los hace muy adecuados para experiencias de aprendizaje orientadas a objetivos [35].

A pesar de estos beneficios, se deben abordar varios desafíos para asegurar el funcionamiento efectivo de los ITS orientados a objetivos impulsados por LLM. En primer lugar, identificar con precisión las brechas de habilidades del aprendiz en relación con sus objetivos específicos es crítico, es decir, mapear los objetivos del aprendiz a las nuevas habilidades requeridas para el progreso. Esto requiere que los LLMs manejen una comprensión matizada tanto del perfil del estudiante como del objetivo. En segundo lugar, el modelado robusto del aprendiz es fundamental para capturar las preferencias individuales, el progreso y las habilidades cognitivas. El sistema debe adaptarse continuamente a la retroalimentación en tiempo real, asegurando que la experiencia de aprendizaje evolucione con las necesidades y habilidades del estudiante, mientras ajusta dinámicamente las estrategias basadas en el estado del estudiante. En tercer lugar, la provisión de recursos personalizados, por ejemplo, tanto las vías de aprendizaje como el contenido entregado, facilita una adquisición eficiente del conocimiento. El sistema debe garantizar que los recursos sean relevantes, estén alineados con los objetivos y se adapten al progreso del estudiante, presentando los desafíos en la curación de contenido y la optimización del camino de aprendizaje.

En este trabajo, presentamos **GenMentor**, un ITS multiagente impulsado por LLM diseñado para ofrecer una experiencia de aprendizaje personalizada y orientada a objetivos. Para abordar las diversas funciones requeridas en los ITS, distribuimos responsabilidades entre múltiples agentes de LLM, lo que les permite gestionar tareas distintas de forma colaborativa [12]. Específicamente, para mejorar la relevancia y la alineación de objetivos de las habilidades identificadas, personalizamos un conjunto de datos de objetivo a destreza para ajustar el LLM como *habilidad identificable*, que contribuye a la correspondencia precisa de los objetivos de aprendizaje con las habilidades necesarias. Luego, este agente identifica la brecha de habilidades teniendo en cuenta adicionalmente la información inicial del estudiante. Para habilitar la personalización específica del alumno, empleamos un sistema adaptativo *perfilador de aprendizaje* para

Seguir dinámicamente el estado cognitivo, las preferencias y los patrones de comportamiento del estudiante. Al integrar interacciones en tiempo real, también actualiza continuamente el perfil del estudiante para una comprensión más profunda y precisa. Además, para cerrar la brecha de habilidades identificada, el *planificador de rutas* refina continuamente el camino de aprendizaje para el logro efectivo de los objetivos, donde un *simulador de aprendizaje* con el perfil generado se utiliza para imitar la retroalimentación del estudiante sobre los recursos proporcionados. También implementamos un *creador de contenido* con un mecanismo de exploración-generación-integración, es decir, primero explorar el conocimiento orientado a objetivos y preparar un esquema, luego redactar cada sección y finalmente integrarlas y refinarlas para crear materiales de aprendizaje. Este proceso garantiza que el contenido entregado se mantenga alineado con los objetivos del estudiante, al tiempo que mejora la personalización y la efectividad. Para evaluar la efectividad de GenMentor, llevamos a cabo evaluaciones tanto automatizadas como humanas, que muestran su superioridad en los requisitos de habilidades identificados, las rutas de aprendizaje programadas y el contenido generado. Además, lo hemos desplegado en el producto práctico e implementado una aplicación independiente diseñada para el aprendizaje profesional de los empleados y el logro de objetivos. Un estudio humano destaca aún más su eficacia a la hora de proporcionar orientación para el aprendizaje y recursos específicos, y facilitar el logro de los objetivos.

Resumimos las principales contribuciones de nuestro trabajo como sigue:

- Presentamos una perspectiva novedosa sobre el ITS, un aprendizaje orientado a objetivos-ing, para satisfacer las necesidades educativas prácticas de los estudiantes. A través de la integración de LLMs, proponemos GenMentor, un sistema multi-agente LLM para implementar esta filosofía.
- Para mejorar la alineación de objetivos entre las habilidades identificadas, construimos un objetivo-Conjunto de datos de mapeo a habilidades para el ajuste fino del LLM. Basados en teorías educativas, proponemos un método de modelado adaptativo del alumno para captar las necesidades cambiantes. Diseñamos una programación de caminos de aprendizaje evolutiva y un método de exploración-borrador-integración para mejorar la personalización de los recursos.
- Realizamos experimentos extensos a través de ambos automatizados y evaluación humana. Los resultados demuestran que Gen-Mentor ofrece una orientación y recursos de aprendizaje superiores.
- Desplegamos GenMentor en un producto práctico e implementamos como una aplicación. Un estudio con estudiantes profesionales también muestra su eficacia para lograr un aprendizaje orientado a objetivos.

2 Obras relacionadas

2.1 Sistema de tutoría inteligente

Los sistemas de tutoría inteligente (ITS) están diseñados para proporcionar experiencias personalizadas, imitando la tutoría humana individual [4]. Con los avances en el aprendizaje automático, los ITS modernos se han desplazado hacia el aprovechamiento de enfoques basados en datos para la gestión de materiales [19, 39], el modelado de aprendices [10, 31] y la provisión de retroalimentación [13, 42]. A pesar de estos avances, los ITS basados en ML existentes a menudo combinan varios modelos basados en ML para tareas distintas, lo que resulta en inconsistencias técnicas y fragmentación de datos, y falta de generabilidad para temas emergentes. Además, se basan en contenidos estáticos y planes de estudios predefinidos, centrándose en la adquisición general de conocimientos en lugar de adaptarse dinámicamente a los objetivos individuales del alumno. Recientemente, varios trabajos [8, 9, 20, 26] han integrado LLMs en ITS como un tutor conversacional debido a sus excelentes habilidades en la comprensión y generación de LLMs. De lo contrario, estos sistemas no pueden guiar proactivamente a los estudiantes hacia sus objetivos de largo plazo debido a su naturaleza reactiva y el compromiso basado en el diálogo.

En nuestro trabajo, exploramos un marco unificado de trabajo multiagente basado en LLM para ITS, que aborda la fragmentación que a menudo surge de modelos de aprendizaje automático tradicionales separados para ITS y mejora la consistencia a lo largo de las fases de tutoría. Además, nos centramos en proporcionar una orientación de aprendizaje proactiva para el logro de los objetivos, que difiere del ITS tradicional para la adquisición amplia de conocimientos.

2.2 Sistemas multiagentes con motor LLM

A diferencia de los agentes LLM individuales que operan de forma independiente, los sistemas multiagente basados en LLM emplean múltiples agentes LLM con diferentes perfiles para abordar las tareas de manera colaborativa [12]. Al distribuir las responsabilidades, estos sistemas pueden abordar desafíos más dinámicos y complejos. Este enfoque ha mostrado resultados prometedores en varios ámbitos, como el desarrollo de software [27], el agente incorporado [22] y el juego [38]. Por ejemplo, en el desarrollo de software, se propuso un marco basado en chat donde los agentes de LLM colaboran a través de diferentes fases (es decir, diseño, codificación y pruebas), a través de una comunicación unificada basada en el lenguaje. Además, los agentes múltiples de LLM se han explorado en la simulación social [18, 25], donde simulan comportamientos humanos y proporcionan retroalimentación, midiendo las interacciones del mundo real. Estos estudios destacan las capacidades humanas de los agentes de LLM y ofrecen valiosas perspectivas sobre el comportamiento humano y la toma de decisiones. En el contexto de los STI, implican tareas complejas y en evolución como la generación de contenido personalizado, el diseño adaptativo del camino de aprendizaje y el procesamiento en tiempo real de la retroalimentación de los estudiantes. Para manejar estas complejidades y mejorar la consistencia general, aprovechamos el poder colaborativo de los agentes LLM en ITS que proviene de su capacidad para manejar múltiples roles especializados, permitiendo experiencias de aprendizaje más personalizadas y adaptables.

3 Declaración del problema

En el aprendizaje orientado a objetivos, el foco está en lograr objetivos específicos de manera eficiente, como completar un proyecto o dominar habilidades relacionadas con el trabajo. Esto requiere una orientación proactiva para evitar el aprendizaje desenfocado y mejorar la eficiencia de la consecución de objetivos. Un ITS orientado a objetivos tiene como objetivo personalizar los itinerarios y contenidos de aprendizaje, permitiendo que los estudiantes adquieran rápidamente el conocimiento necesario para satisfacer sus objetivos específicos. Formalmente, dejemos $O = (O, \dots)$ representar al alumno

perfil, donde O , $\dots$, denota el conocimiento inicial del estudiante status, preferencias y patrones de comportamiento, respectivamente. Con un objetivo específico Δ , el alumno debe dominar un conjunto de habilidades necesario para lograr este objetivo. Nuestro objetivo es minimizar eficientemente la habilidad gap $\Delta O = \Delta - O$ con una experiencia de aprendizaje personalizada y adaptativa, basado en Δ y las interacciones en tiempo real de los alumnos. A través programando un camino de aprendizaje personalizado y de medida lograr esto, el sistema debe abordar tres sub tareas clave:

- **Identificación de la brecha de habilidades.** Este paso identifica la brecha de habilidades entre el conocimiento actual de los estudiantes y las habilidades necesarias para alcanzar sus metas. Primero, objetivo Δ está relacionado con el Δ , y luego la brecha de habilidades ΔO es identificada como $\Delta O = \Delta - O$, donde el O se deriva

de la información individual proporcionada por el alumno O .

- **Modelado adaptativo del alumno.** Este módulo se actualiza continuamente perfiles de aprendizaje de fecha mediante la incorporación de datos de

Tiempo límite Δ , restar $(\Delta, \Delta O, \dots)$ (Δ, Δ) . Esto interacción Δ permite al sistema seguir el progreso cognitivo, reconocer aprender las preferencias, identificar y los patrones de comportamiento.

- **Entrega de recursos personalizada.** Para cerrar la habilidad de manera eficiente gap Δ , este módulo planifica dinámicamente una ruta de aprendizaje atractiva y ofrece contenidos de aprendizaje personalizados, es decir, (Δ, Δ) (Δ, Δ) . El camino debe adaptarse al

el progreso y las preferencias evolutivas del estudiante, mientras que el con- la tienda debe ser de alta calidad, relevante para el objetivo y personalizada.

4 El marco GenMentor

En este trabajo, proponemos un marco multiagente impulsado por LLM para el aprendizaje orientado a objetivos en ITS, llamado GenMentor. Para abordar las sub tareas intrincadas anteriores, distribuimos responsabilidades entre varios agentes de LLM, lo que les permite gestionar diferentes tareas de forma colaborativa. Como se ilustra en la figura 2, este sistema comienza con una evaluación precisa de la brecha de habilidades entre las habilidades actuales del aprendiz y el objetivo. Una vez que se identifica esta brecha, el ITS genera un camino de aprendizaje personalizado con un método de optimización evolutiva tanto para la eficiencia del aprendizaje como para el compromiso. Además, el sistema organiza y genera contenido orientado a objetivos, actualizado y adaptado a las necesidades específicas del alumno, asegurando que el alumno se centre en el contenido más relevante y dirigido. Durante el proceso de aprendizaje, los perfiles generados del aprendiz se ajustan continuamente con las interacciones del recién llegado, permitiendo una adaptación dinámica al progreso, preferencias y necesidades cambiantes del aprendiz.

4.1 Identificación de la brecha de habilidades

Para personalizar la experiencia de aprendizaje hacia el logro de objetivos específicos, identificamos la brecha de habilidades, es decir, las habilidades necesarias que cubren el estado cognitivo actual del estudiante y los objetivos. Mapear estos objetivos con precisión requiere que el LLM entienda los matices del objetivo, dada su naturaleza a menudo abstracta y de alto nivel. Sin embargo, la inducción directa de LLMs puede producir habilidades irrelevantes, innecesarias o incompletas, impidiendo el logro efectivo del objetivo. Por lo tanto, construimos un conjunto de datos personalizado de objetivo a habilidades con Chain of Thought (CoT) [36] para ajustar los LLMs, mejorando la alineación de objetivos de las brechas identificadas.

4.1.1 Construcción de conjuntos de datos habilitados para CoT. Dada la ausencia de un conjunto de datos directamente relevante para nuestra tarea, recurrimos a los conjuntos de datos de anuncios de empleo, que contienen información detallada sobre roles laborales, descripciones y habilidades requeridas. Estos conjuntos de datos proporcionan información fundamental sobre las expectativas y los requisitos para varios roles. Extrayendo pares de resúmenes de puestos (que incluyen roles y descripciones breves de puestos) y sus correspondientes habilidades básicas, construimos un conjunto de datos objetivo-a-habilidad, tratando estos resúmenes de puestos como metas. Sin embargo, el ajuste directo de estos conjuntos de datos puede no ser suficiente para asignar con precisión los objetivos a las habilidades, en gran medida debido al lenguaje abstracto y de alto nivel común en las descripciones de puestos. Para abordar esta limitación, empleamos el razonamiento CoT [36], introduciendo pasos intermedios que aclaran las conexiones lógicas entre las responsabilidades laborales y las habilidades necesarias. El proceso CoT implica dividir los objetivos en tareas clave, identificar las habilidades requeridas para cada tarea y determinar los niveles de competencia necesarios, produciendo muestras de <job summary, reasoning tracks, required skills>. Véase el apéndice A.1 para más detalles. Este enfoque facilita la captura de las relaciones matizadas entre objetivos y habilidades, mejorando así la precisión del ajuste.

4.1.2 Ajuste preciso del LLM para la alineación de objetivos. Utilizando el conjunto de datos construido del objetivo-a-destreza, afinamos el LLM como *identificador de habilidades* para asignar con precisión objetivos a habilidades específicas. Este paso garantiza que esto




Figura 2: Visión general de GenMentor: un marco multiagente impulsado por LLM para el aprendizaje orientado a objetivos en ITS.

agente identifica habilidades relevantes y completas mientras filtra las habilidades innecesarias, centrándose en el logro eficiente de los objetivos.

4.1.3 Proceso de identificación de brechas. Este proceso comienza con el mapeo de metas a habilidades, $= \text{identificador de habilidades}()$, donde el objetivo de aprendizaje se corresponde con un conjunto de habilidades que son las competencias básicas necesarias para el gol. Luego, las habilidades identificadas se comparan con el estado cognitivo inicial del estudiante basado en la información proporcionada para establecer la brecha de habilidades, $\Delta = \text{identificador de habilidades}(), 0$. Este paso elimina los filtros habilidades ya dominadas y resalta áreas que necesitan mejora.

4.2 Modelado adaptativo del alumno

Entender el estatus del estudiante es esencial para el ITS, ya que personaliza el aprendizaje adaptando el contenido a sus necesidades y proporcionando retroalimentación dirigida [2]. En lugar de los métodos tradicionales basados en el aprendizaje automático que carecen de generalización e integración, mientras que el diálogo basado en LLM sigue siendo reactivo, aquí exploramos cómo aprovechar explícitamente LLM para lograr el perfil integral y dinámico del estudiante.

4.2.1 Perfil completo del alumno. Para capturar el estado de conocimiento del estudiante y proporcionar recursos de aprendizaje personalizados que se alineen con los objetivos y preferencias, consideramos tres aspectos fundamentales para crear un perfil de aprendizaje integral, informado por teorías educativas [2, 30]. Estos aspectos son los siguientes:

- **Estado cognitivo.** Para monitorear el conocimiento del estudiante acquisition, seguimos el progreso del aprendizaje y evaluamos el dominio de las habilidades requeridas. Representamos estas habilidades como un conjunto de capacidades que el aprendiz ha dominado y aquellas que todavía necesita adquirir, junto con las métricas correspondientes de progreso y dominio. Este enfoque resalta las brechas de habilidades restantes y permite que el sistema proporcione contenido específico para ayudar al estudiante a alcanzar sus metas.
- **Preferencias de aprendizaje.** Reconocer las diversas maneras de aprender-Para absorber la información, este aspecto capta las preferencias individuales como los estilos de contenido preferidos (por ejemplo, resumen conciso, explicaciones detalladas) y los tipos de actividad preferidos

(por ejemplo, lectura, consulta activa, ejercicios interactivos). Estos conocimientos permiten al sistema adaptar sus métodos de instrucción y ajustar dinámicamente la entrega de contenido para mejorar el compromiso del alumno y la comprensión del conocimiento.

- **Patrones de comportamiento.** Al analizar los datos de interacción, nos proponemos Identificar las tendencias conductuales que afectan la participación en el aprendizaje, como la frecuencia de uso del sistema y la variabilidad del consumo de tiempo de las sesiones de aprendizaje. El uso poco frecuente y el consumo de tiempo irregular (por ejemplo, mucho tiempo pasado en una sesión) pueden indicar desconexión o dificultad. Estos conocimientos permiten intervenciones proactivas, como mensajes motivacionales o dificultad de contenido ajustado, para mantener el impulso del alumno hacia sus objetivos.

4.2.2 Modelado dinámico del aprendizaje. Inicialmente, sobre la base de la información proporcionada al alumno 0 (por ejemplo, currículum) y deficiencias de habilidades identificadas Δ , usamos un *perfilador de aprendizaje* crear un perfil preliminar, es decir, $0 = \text{Aprendiz-perfilador} (0, \Delta, 0)$, captar los tres aspectos mencionados anteriormente. Este perfil inicial sirve como punto de partida, puede tener limitaciones o imprecisiones. A medida que el estudiante interactúa con el sistema, su perfil se actualiza y refina continuamente en base a las interacciones dinámicas recopiladas. (por ejemplo, datos de rendimiento en tiempo real y proactivos retroalimentación) en cada momento t , es decir, $t = \text{Aprendiz-perfilador} (t, \Delta_t, t)$.

Durante cada sesión de aprendizaje en el horario t , el sistema recoge Retroalimentación del alumno y seguimiento de métricas como el rendimiento y el uso del tiempo como datos de interacción. Para *preferencias de aprendizaje*, Los datos sobre el tiempo dedicado a diferentes actividades y comentarios identifican el contenido preferido, lo que permite un ajuste dinámico del contenido instruccional. Para el examen, si un estudiante prefiere ejercicios interactivos, el sistema prioriza estas actividades ofreciendo más ejercicios. En relación con *patrones de comportamiento*, La frecuencia de uso de la plataforma y la consistencia del compromiso ayudan a medir la motivación. Por ejemplo, los patrones irregulares (p. ej., duraciones prolongadas en sesiones individuales o inicios de sesión infrecuentes) inducen intervenciones como el desencadenamiento de mensajes motivacionales o la dificultad ajustada del contenido para mantener el compromiso y prevenir la frustración. Después




Figura 3: Una ilustración del modelado dinámico de aprendices.

En cada sesión, el sistema evalúa el progreso de *estado cognitivo* por los resultados de las pruebas y la retroalimentación comunicada por el alumno. Actualiza el proceso de aprendizaje y el dominio de las habilidades e identifica la brecha de habilidades restante para el aprendizaje futuro. En la figura 3 se muestra un ejemplo ilustrativo.

4.3 Entrega personalizada de recursos

Para cerrar eficazmente las brechas de habilidades identificadas, GenMentor emplea un método personalizado y adaptativo de entrega de contenido que alinea dinámicamente los recursos con el perfil único y el progreso de cada estudiante. Concretamente, dada la brecha de habilidades Δ 0 y perfil del alumno O obtenido en la etapa anterior, el *calendario de rutas* crea un camino de aprendizaje $= n, 1, 2, \dots$, que consiste en múltiples sesiones de aprendizaje. Para cada sesión de aprendizaje, *creador de contenido* personalizar el contenido con un mecanismo de exploración-redacción-integración para mejorar la personalización y el targeting del reabastecimiento. Durante el proceso de aprendizaje, un *simulador de aprendizaje* usar el perfil de estudiante dinámico se emplea para imitar la retroalimentación del estudiante sobre los recursos de aprendizaje para su perfeccionamiento, permitiendo la adaptación del camino y el contenido de aprendizaje.

4.3.1 Simulador de aprendices a través del Perfil Adaptativo. Para lograr la adaptación de los recursos de aprendizaje al tiempo que minimizamos la dependencia de la retroalimentación directa del usuario, diseñamos un mecanismo de retroalimentación basado en el agente LLM que simula las respuestas del alumno [11]. Específicamente, los perfiles de aprendices en tiempo real que se pueden activar, a *simulador de aprendizaje* emplea el método del juego de roles para anticipar la retroalimentación de los alumnos sobre las fuentes entregadas [28]. Esta simulación sirve como un proxy para optimizar los recursos entregados sin requerir retroalimentación directa del estudiante. Para los caminos de aprendizaje, el *simulador de aprendizaje* evalúa factores como la eficiencia, el compromiso y la dificultad de la tarea, mientras anticipa las reacciones del alumno ante contenidos personalizados (por ejemplo, pedir más ejercicio o dar retroalimentación con dificultades demasiado altas). Este método permite al sistema ajustar proactivamente el recurso de aprendizaje para que coincida mejor con las intenciones y preferencias del alumno, maximizando la comprensión y manteniendo la motivación.

4.3.2 Planificación de la ruta de aprendizaje evolutiva. Usamos un *planificador de rutas* equipado con la capacidad de razonamiento CoT para planificar vías de aprendizaje efectivas y comprometidas que apoyen eficazmente la adquisición de habilidades. Inicialmente, construye un camino de aprendizaje inicial $O = \text{LLMpath-scheduler} (0, \Delta, 0)$

basado en esta brecha se refina iterativamente con la retroalimentación del simulador de aprendizaje, asegurando que el camino de aprendizaje se vuelva progresivamente desafiante y motivador para el estudiante. A medida que avanza el proceso de aprendizaje, el perfil del estudiante se actualiza continuamente para incorporar ideas a las preferencias, habilidades y progreso cambiantes del estudiante. Después de completar una sesión a tiempo, el programador de rutas reevalúa y ajusta dinámicamente la información n camino 1 con el perfil actualizado, mientras se genera

$\text{LLMpath-scheduler}(\Delta, 1)$. Si el estudiante lo aprueba, la subida ruta de aprendizaje antigua sustituye al anterior. Iterativamente Evaluar y ajustar el camino de aprendizaje, este mecanismo de programación adaptativa garantiza la alineación con las necesidades cambiantes del estudiante.

4.3.3 Curación de contenido personalizado. Para ofrecer a los estudiantes contenidos de aprendizaje relevantes y personalizados, GenMentor emplea un *creador de contenido* con un mecanismo de exploración-redacción-integración para seleccionar materiales, incluidos documentos y cuestionarios. Para garantizar la precisión y la información actualizada, el creador de contenido integra herramientas de búsqueda web para la generación aumentada por recuperación (RAG). Específicamente, para una sesión de aprendizaje dada, el *creador de contenido* comienza con la exploración para identificar puntos de conocimiento relacionados con los objetivos en diversas perspectivas. Luego redacta el contenido basado en un esquema de documento sistemático que considera las preferencias del estudiante, y finalmente integra la retroalimentación del simulador del estudiante para refinar y finalizar el material de aprendizaje. Este enfoque garantiza que el contenido siga siendo preciso y centrado en el alumno, facilitando la consecución de los objetivos.

Exploración del conocimiento orientada a objetivos. Se identifican los puntos clave del conocimiento para asegurar que el contenido de aprendizaje sea completo y esté alineado con los objetivos del estudiante. Guiado por el aprendizaje práctico [32, 34], el contenido cubre conceptos fundamentales que proporcionan los conocimientos previos necesarios, ideas prácticas que ayudan a cerrar la brecha entre el conocimiento teórico y la aplicación en el mundo real, y problemas-resolver estrategias que equipan a los estudiantes con técnicas para enfrentar desafíos, fomentando el pensamiento crítico y la adaptabilidad. El *creador de contenido* utiliza el título de la sesión como una consulta, para recuperar la información más reciente. Combinando esta información actualizada con el conocimiento inherente del LLM, identifica los puntos de conocimiento relevantes y los organiza en un esquema de documento estructurado. Esto esquema, derivado por $= \text{LLMcontent-creator}(\Delta, \dots)$, sirve como la base para la redacción posterior, asegurando que el contenido sigue siendo objetivo, actual y alineado con los objetivos del alumno.

Redacción de secciones basada en RAG. Al redactar el contenido de cada sección, para mitigar problemas comunes en la generación directa de LLM como alucinaciones e inexactitudes de cola larga [16, 37], el creador del contenido integra información recuperada de alta calidad. Se formó consultas combinando el título de la sesión y los títulos de las secciones para recuperar datos relevantes y confiables. Esta información recuperada se vuelve a personalizar para alinearla con el perfil del estudiante, asegurando que el contenido sea tanto informativo como atractivo. Estos borradores de sección, $= \text{creador de contenido}(\Delta, \dots)$, están adaptados para coincidir con el

las preferencias y el progreso del alumno, mejorando la personalización un documento cohesivo y luego el simulador del aprendiz proporciona la retroalimentación imitada del aprendiz y evalúa la estructura lógica y la coherencia. El creador de contenido refina las secciones que requieren mejora, asegurándose de que cada parte esté alineada con las necesidades del estudiante. Una vez refinadas, estas secciones se integran sin problemas en el documento de aprendizaje final. Los cuestionarios se generan junto con el documento para mejorar la participación del alumno y poner a prueba su dominio del conocimiento. Este proceso se denota como $= \text{creador de contenido}(\Delta, \dots)$. Esto

adaptado al alumno, promoviendo tanto la comprensión como la motivación. El método garantiza además que el contenido final esté organizado de forma lógica y

5 experimentos

Para evaluar la efectividad de los elementos de salida de GenMentor, realizamos evaluaciones tanto automatizadas como humanas basadas en LLM.